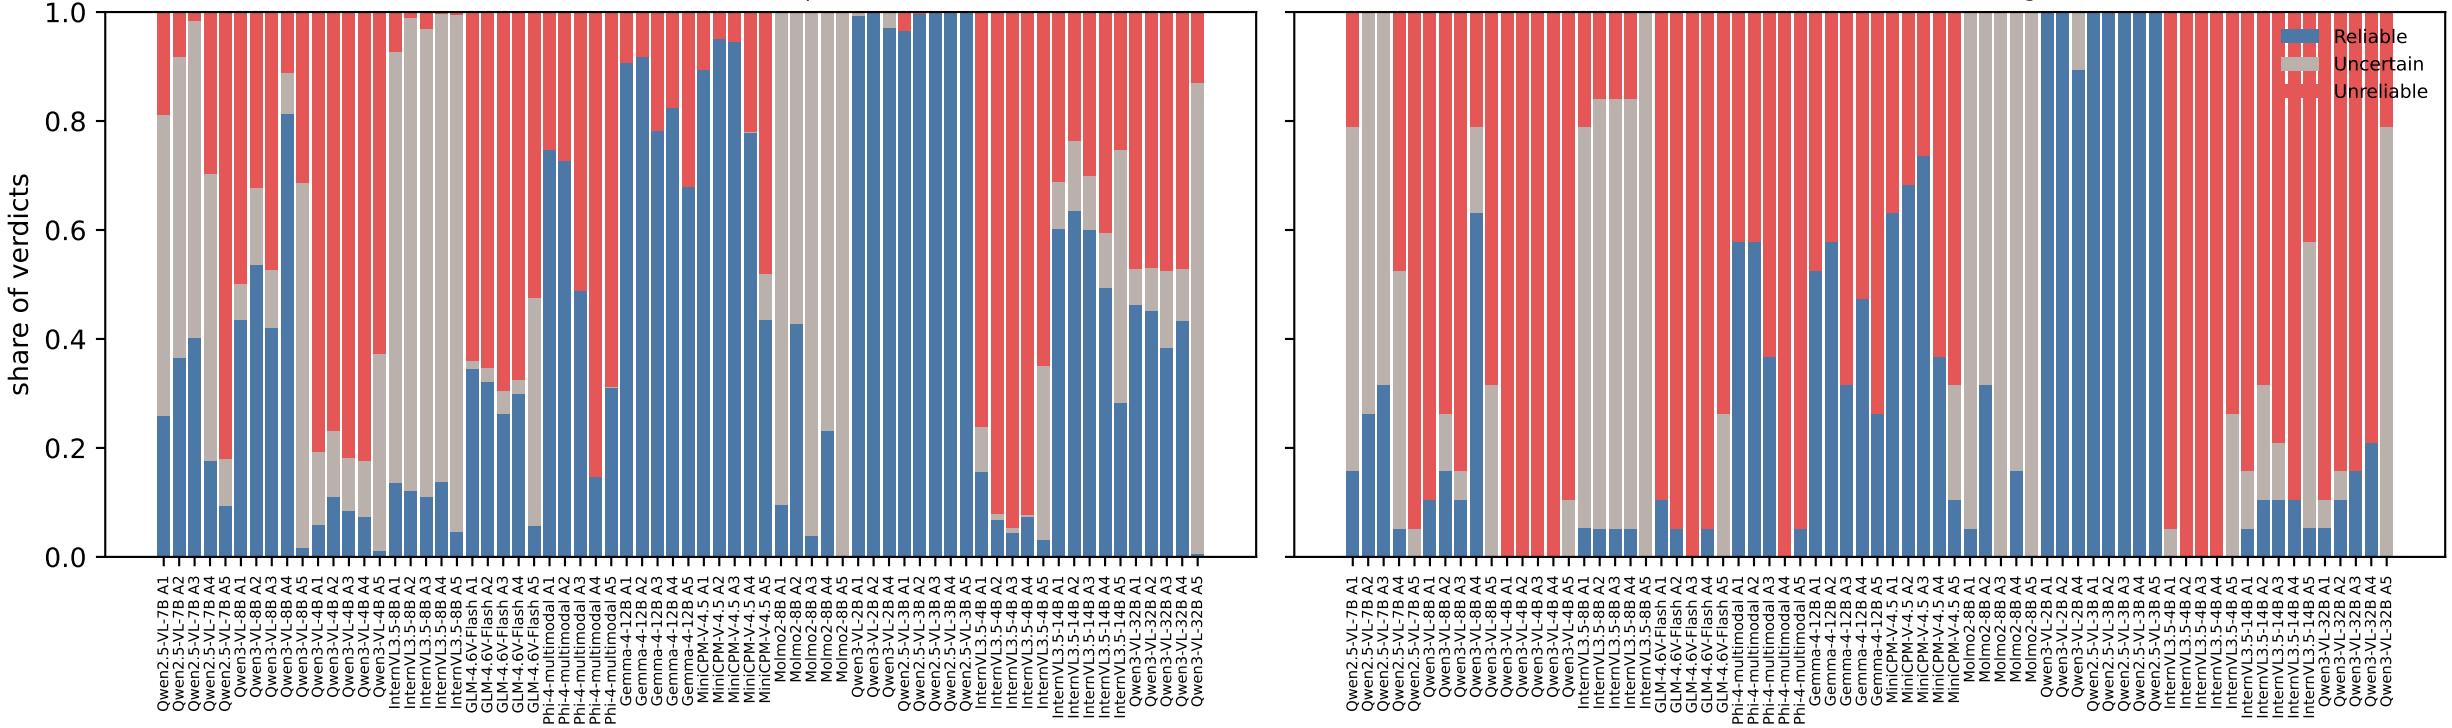
LabelMe-unmatched, human label = palm (n = 619)
LabelMe-unmatched, human label = ambiguous (n = 19)
share of verdicts
1.0
0.8
0.6
0.4
0.2
0.0
Reliable
Uncertain
Unreliable
Qwen2.5-VL-7B A1
Qwen2.5-VL-7B A2
Qwen2.5-VL-7B A3
Qwen2.5-VL-7B A4
Qwen2.5-VL-7B A5
Qwen3-VL-8B A1
Qwen3-VL-8B A2
Qwen3-VL-8B A3
Qwen3-VL-8B A4
Qwen3-VL-8B A5
Qwen3-VL-4B A1
Qwen3-VL-4B A2
Qwen3-VL-4B A3
Qwen3-VL-4B A4
Qwen3-VL-4B A5
InternVL3.5-8B A1
InternVL3.5-8B A2
InternVL3.5-8B A3
InternVL3.5-8B A4
InternVL3.5-8B A5
GLM-4.6V-Flash A1
GLM-4.6V-Flash A2
GLM-4.6V-Flash A3
GLM-4.6V-Flash A4
GLM-4.6V-Flash A5
Phi-4-multimodal A1
Phi-4-multimodal A2
Phi-4-multimodal A3
Phi-4-multimodal A4
Phi-4-multimodal A5
Gemma-4-12B A1
Gemma-4-12B A2
Gemma-4-12B A3
Gemma-4-12B A4
Gemma-4-12B A5
MiniCPM-V-4.5 A1
MiniCPM-V-4.5 A2
MiniCPM-V-4.5 A3
MiniCPM-V-4.5 A4
MiniCPM-V-4.5 A5
Molmo2-8B A1
Molmo2-8B A2
Molmo2-8B A3
Molmo2-8B A4
Molmo2-8B A5
Qwen3-VL-2B A1
Qwen3-VL-2B A2
Qwen3-VL-2B A3
Qwen3-VL-2B A4
Qwen3-VL-2B A5
Qwen2.5-VL-3B A1
Qwen2.5-VL-3B A2
Qwen2.5-VL-3B A3
Qwen2.5-VL-3B A4
Qwen2.5-VL-3B A5
InternVL3.5-4B A1
InternVL3.5-4B A2
InternVL3.5-4B A3
InternVL3.5-4B A4
InternVL3.5-4B A5
InternVL3.5-14B A1
InternVL3.5-14B A2
InternVL3.5-14B A3
InternVL3.5-14B A4
InternVL3.5-14B A5
Qwen3-VL-32B A1
Qwen3-VL-32B A2
Qwen3-VL-32B A3
Qwen3-VL-32B A4
Qwen3-VL-32B A5